

Klasifikácia rakoviny prsníka pomocou modelov strojového učenia

Finálna dokumentácia semestrálneho projektu IB031

Richard Golian

Filip Kudera

Juraj Polhorský

23. mája 2026

Abstrakt

Cieľom projektu je vytvoriť a vyhodnotiť modely strojového učenia na binárnu klasifikáciu nádorových buniek prsníka na benígne a malígne. Pracujeme s datasetom Breast Cancer, ktorý obsahuje numerické vlastnosti buniek získané z vyšetrenia vzoriek. V práci popisujeme exploračnú analýzu dát, čistenie a predspracovanie, tréning troch modelov, interpretáciu naučených modelov a porovnanie výsledkov voči jednoduchému baseline modelu. Najlepšie výsledky na testovacej množine dosiahol model SVM s accuracy 98.25 % a F1 skóre 0.9762.

Obsah


1	Úvod a cieľ projektu	2
2	Popis datasetu	2
3	Exploračná analýza dát	3
4	Predspracovanie dát	3
4.1	Čistenie datasetu	3
4.2	Výber vstupných premenných	4
4.3	Pipeline	4
5	Použité modely	4
5.1	Baseline model: DummyClassifier	4
5.2	Logistic Regression	5
5.3	Support Vector Machine	7
5.4	Random Forest	8
6	Vyhodnotenie modelov	10
7	Diskusia výsledkov	11
8	Záver	11

1 Úvod a cieľ projektu

V projekte riešime úlohu binárnej klasifikácie. Pre každú vzorku chceme predikovať, či ide o benígny nádor alebo malígny nádor. Cieľová premenná *diagnosis* má dve hodnoty:

- B – benígny nádor,
- M – malígny nádor.

Táto úloha je z medicínskeho hľadiska citlivá, pretože prehliadnutie malígnej vzorky je výrazne závažnejšie ako falošný poplach. Z toho dôvodu pri hodnotení sledujeme nielen accuracy, ale aj precision, recall a F1 skóre, pričom pozitívnou triedou je trieda M.



Obr. 1: Ilustračné príklady benígnych a malígnych vzoriek pri rôznych zväčšeniach. Obrázok slúži na intuitívne znázornenie rozdielov medzi triedami.

2 Popis datasetu

Po základnom vyčistení dataset obsahoval 568 vzoriek a 32 stĺpcov. Vzorky opisujú morfológické vlastnosti buniek, napríklad polomer, textúru, plochu, hladkosť, kompaktnosť, konkávnosť, počet konkávných bodov, symetriu a fraktálnu dimenziu. Pre väčšinu vlastností sú dostupné tri typy štatistík: priemer, štandardná chyba a najhoršia hodnota.

Tabuľka 1: Prehľad typov premenných v datasete.

Typ stĺpca	Význam
id, prípadne index	Identifikátory záznamov. Nepoužívajú sa pri učení modelov, pretože nenesú medicínsku informáciu.
diagnosis	Cieľová premenná. Hodnota B znamená benígny nádor a hodnota M malígny nádor.
Numerické features	Vlastnosti buniek, napríklad radius, texture, area, smoothness, compactness, concavity, symmetry.

Použité základné vlastnosti sú:

- `radius` – polomer,
- `texture` – textúra, teda variabilita hodnôt v odtieňoch sivej,
- `perimeter` – obvod,
- `area` – plocha,
- `smoothness` – hladkosť,
- `compactness` – kompaktnosť,
- `concavity` – konkávnosť,
- `concave points` – počet konkávných bodov,
- `symmetry` – symetria,
- `fractal_dimension` – fraktálna dimenzia.

3 Exploračná analýza dát

Exploračná analýza slúžila na pochopenie štruktúry datasetu, kontroly kvality dát a vzťahov medzi premennými. V notebooku sme skontrolovali tvar datasetu, dátové typy, chýbajúce hodnoty, distribúciu tried a základné štatistiky numerických premenných.

Pre lepšie pochopenie dát boli použité:

- graf rozdelenia tried,
- histogramy vybraných numerických premenných,
- boxploty podľa diagnózy,
- korelačná matica,
- pairplot vybraných premenných,
- PCA projekcia do dvoch dimenzií.

Korelačná analýza ukázala silnú koreláciu medzi premennými `radius`, `perimeter` a `area`, pretože všetky opisujú veľkosť nádoru. Z praktického hľadiska by použitie všetkých týchto premenných mohlo viesť k redundancii. Preto sme v modelových dátach ponechali premenné typu `area_*` a odstránili `perimeter_*`.

PCA vizualizácia naznačila, že triedy sa v redukovanom dvojrozmernom priestore do určitej miery oddeľujú. To podporuje predpoklad, že dataset je vhodný pre klasifikačné modely.

4 Predspracovanie dát

Predspracovanie bolo navrhnuté tak, aby sa minimalizovalo riziko úniku informácie z testovacej množiny do trénovania. Najdôležitejšie kroky boli vykonané buď pred rozdelením dát len vtedy, keď nevyužívali cieľovú informáciu, alebo priamo v `Pipeline` počas cross-validácie.

4.1 Čistenie datasetu

Funkcia `prepare_dataset()` vykonala tieto kroky:

1. načítanie Excel súboru a preskočenie prvých 12 riadkov hlavičky,
2. odstránenie úplne prázdnych stĺpcov a nevalidných riadkov,
3. zjednotenie hodnôt v `diagnosis` na B a M,
4. prevod numerických stĺpcov na čísla,
5. odstránenie riadkov s viac ako 30 % chýbajúcich hodnôt,

6. orezanie extrémnych hodnôt medzi 3. a 97. percentilom,
7. premenovanie stĺpcov do čitateľného formátu `*_mean`, `*_se`, `*_worst`,
8. odstránenie duplicitných riadkov a duplicitných záznamov podľa `id`.

4.2 Výber vstupných premenných

Z modelových dát boli odstránené:

- identifikátory `id` a prípadne `index`,
- cieľová premenná `diagnosis`,
- redundantné stĺpce `perimeter_mean`, `perimeter_se`, `perimeter_worst`.

Po odstránení týchto stĺpcov zostalo 27 vstupných features. Dáta boli rozdelené stratifikovane na trénovaciu a testovaciu množinu v pomere 80/20:

- trénovacia množina: 454 vzoriek,
- testovacia množina: 114 vzoriek.

4.3 Pipeline

Pre modely bola použitá jednotná pipeline:

1. `SimpleImputer(strategy="median")` – doplnenie chýbajúcich hodnôt mediánom,
2. `StandardScaler()` – štandardizácia numerických features,
3. `SelectKBest(score_func=f_classif)` – výber najinformatívnejších features,
4. konkrétny klasifikačný model.

Výber features pomocou `SelectKBest` je súčasťou pipeline, takže sa učí iba z trénovacích foldov počas cross-validácie. Tým sa predchádza data leakage.

5 Použité modely


V projekte boli porovnané tri klasifikačné modely a jeden naivný baseline model:

- Logistic Regression,
- Support Vector Machine,
- Random Forest,
- Dummy Baseline.

Hyperparametre boli ladené pomocou `GridSearchCV`. Ako hlavná optimalizačná metrika bolo použité F1 skóre, pretože kombinuje precision a recall a je vhodnejšie než samotná accuracy pri citlivejších klasifikačných úlohách.

5.1 Baseline model: `DummyClassifier`

Ako baseline bol použitý `DummyClassifier` so stratégiou `constant`, ktorý vždy predikuje triedu 1, teda malígny nádor. Tento baseline je zámerne jednoduchý a slúži na overenie, či trénované modely skutočne prinášajú lepšie rozhodovanie než naivný prístup.



Obr. 2: Confusion matrix pre Dummy Baseline. Model všetky vzorky označuje ako malígne.

Baseline dosiahol accuracy 36.84 % a F1 skóre 0.5385. Recall pre malígnu triedu je síce 1.0, pretože model označí všetky malígne prípady ako malígne, ale za cenu veľkého počtu falošne pozitívnych predikcií. Model zároveň vôbec nerozpoznáva benígne prípady.

5.2 Logistic Regression


Logistická regresia je lineárny klasifikačný model, ktorý odhaduje pravdepodobnosť príslušnosti vzorky k pozitívnej triede. Pre binárnu klasifikáciu používa sigmoid funkciu, ktorá prevedie lineárnu kombináciu vstupných premenných na hodnotu medzi 0 a 1. Ak je výsledná pravdepodobnosť vyššia ako zvolený prah, model predikuje pozitívnu triedu.

Výhodou logistickej regresie je dobrá interpretovateľnosť. Naučené koeficienty ukazujú, ktoré features zvyšujú alebo znižujú pravdepodobnosť predikcie malígnej triedy. V projekte boli ladené hyperparametre `C`, `solver` a počet vybraných features.

Najlepšie parametre:


- `feature_selection__k = all`,
- `model__C = 1`,
- `model__solver = liblinear`.

Model dosiahol na testovacej množine accuracy 97.37 % a F1 skóre 0.9647.



Obr. 3: Confusion matrix pre Logistic Regression.

Logistická regresia urobila iba tri chyby: dve benígne vzorky označila ako maligne a jednu malignu vzorku označila ako benígnu. Z hľadiska medicínskej úlohy je dôležité najmä to, že počet falošne negatívnych predikcií je veľmi nízky.



Obr. 4: Najdôležitejšie features podľa absolútnej hodnoty koeficientov logistickej regresie.

Najvýraznejšie koeficienty mali features ako `area_se`, `concave_points_mean`, `concavity_mean`, `texture_worst`, `smoothness_worst` a `smoothness_se`. To znamená, že model sa silno opiera o veľkosť, tvar a nepravidelnosť buniek.

5.3 Support Vector Machine


Support Vector Machine hľadá rozhodovaciu hranicu, ktorá čo najlepšie oddeľuje triedy v priestore príznačkov. Pri lineárnom jadre ide o nadrovinu, pri nelineárnom jadre, napríklad RBF, model dokáže vytvárať zložitejšie hranice. SVM sa snaží maximalizovať margin, teda vzdialenosť medzi rozhodovacou hranicou a najbližšími tréningovými bodmi.

Pre tento dataset je SVM vhodný, pretože vstupné premenné sú prevažne numerické a po škálovaní majú porovnateľný rozsah. V projekte boli ladené hyperparametre **C**, **kernel**, **gamma** a počet vybraných features.

Najlepšie parametre:


- `feature_selection__k = all`,
- `model__C = 10`,
- `model__gamma = scale`,
- `model__kernel = rbf`.

Model dosiahol na testovacej množine accuracy 98.25 % a F1 skóre 0.9762.



Obr. 5: Confusion matrix pre SVM.

SVM urobil iba dve chyby: jednu falošne pozitívnu a jednu falošne negatívnu predikciu. To je najlepší výsledok zo všetkých testovaných modelov.



Obr. 6: ROC krivka pre SVM. AUC hodnota 0.994 ukazuje veľmi dobrú separáciu tried.

ROC krivka je blízko ľavého horného rohu, čo znamená vysokú mieru true positives pri nízkej miere false positives. AUC 0.994 potvrdzuje, že SVM veľmi dobre rozlišuje medzi benígnymi a malígnymi vzorkami.

5.4 Random Forest


Random Forest je ensemble metóda založená na viacerých rozhodovacích stromoch. Každý strom sa učí na náhodnej podmnožine dát a pri delení uzlov používa náhodný výber features. Finálna predikcia vzniká hlasovaním stromov. Táto metóda je robustná voči nelineárnym vzťahom a dokáže modelovať komplexné interakcie medzi premennými.

Výhodou Random Forest je aj možnosť interpretovať dôležitosť features. V projekte boli ladené hyperparametre `n_estimators`, `max_depth`, `min_samples_leaf` a počet vybraných features.

Najlepšie parametre:


- `feature_selection_k = all`,
- `model__max_depth = None`,
- `model__min_samples_leaf = 1`,
- `model__n_estimators = 100`.

Model dosiahol na testovacej množine accuracy 96.49% a F1 skóre 0.9512.



Obr. 7: Confusion matrix pre Random Forest.

Random Forest správne identifikoval väčšinu vzoriek, ale v porovnaní so SVM a logistickou regresiou mal nižší recall pre malígnu triedu. Konkrétne tri malígne vzorky označil ako benígne, čo je pri tejto úlohe najrizikovejší typ chyby.



Obr. 8: Dôležitosť features podľa modelu Random Forest.

Najdôležitejšie features pre Random Forest boli najmä `concave points_mean`, `area_mean`, `concavity_mean`, `radius_mean`, `concavity_worst`, `concave points_worst` a `area_worst`. To zodpovedá očakávaniu, že veľkosť nádoru a nepravidelnosť tvaru sú dôležité indikátory diagnózy.

6 Vyhodnotenie modelov

Modely boli vyhodnotené na rovnakej testovacej množine s 114 vzorkami. Použité metriky boli:

- **Accuracy** – podiel všetkých správnych predikcií,
- **Precision** – z predikovaných malígnych vzoriek podiel tých, ktoré sú naozaj malígne,
- **Recall** – zo všetkých skutočne malígnych vzoriek podiel tých, ktoré model zachytil,
- **F1 skóre** – harmonický priemer precision a recall.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (1)$$


$$\text{Precision} = \frac{TP}{TP + FP}, \quad (2)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (3)$$


$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (4)$$

Tabuľka 2: Porovnanie modelov na testovacej množine. Pozitívna trieda je malígny nádor.

Model	CV F1	Accuracy	Precision	Recall	Test F1
SVM	0.9422	0.9825	0.9762	0.9762	0.9762
Logistic Regression	0.9431	0.9737	0.9535	0.9762	0.9647
Random Forest	0.9367	0.9649	0.9750	0.9286	0.9512
Dummy Baseline	–	0.3684	0.3684	1.0000	0.5385



Obr. 9: Grafické porovnanie testovacích metrík pre všetky modely.



Obr. 10: Porovnanie confusion matrices všetkých modelov.

7 Diskusia výsledkov

Najlepší model podľa F1 skóre aj accuracy bol SVM. Dosiahol F1 skóre 0.9762 a accuracy 98.25 %. V confusion matrix má iba dve chybné predikcie, jednu falošne pozitívnu a jednu falošne negatívnu. Pri medicínskej diagnostike je nízky počet falošne negatívnych predikcií mimoriadne dôležitý, pretože falošne negatívna predikcia znamená, že skutočne malígny prípad by bol označený ako benígny.

Logistická regresia dosiahla veľmi podobné výsledky ako SVM. Jej veľkou výhodou je interpretovateľnosť, pretože koeficienty priamo ukazujú vplyv jednotlivých features na predikciu. V porovnaní so SVM mala o jednu chybu viac, ale stále dosiahla veľmi vysoké F1 skóre.

Random Forest bol taktiež výrazne lepší než baseline, ale mal najnižší recall spomedzi reálnych modelov. To znamená, že zachytil menší podiel malígnych vzoriek než SVM a logistická regresia. Na druhej strane poskytuje užitočnú interpretáciu pomocou feature importance a potvrdil, že najdôležitejšie sú najmä features súvisiace s veľkosťou a nepravidelnosťou nádoru.

Dummy Baseline ukazuje, že samotné predikovanie malígnej triedy pre všetky vzorky nie je použiteľné riešenie. Aj keď dosahuje recall 1.0 pre malígnu triedu, má veľmi nízku accuracy a veľa falošne pozitívnych predikcií.

8 Záver

Projekt ukázal, že dataset Breast Cancer je dobre klasifikovateľný pomocou viacerých modelov strojového učenia. Po vyčistení dát, odstránení redundantných premenných a použití jednotnej pipeline dosiahli všetky tri reálne modely vysoké výsledky. Najlepší bol SVM s RBF jadrom, ktorý dosiahol najvyššie F1 skóre aj accuracy na testovacej množine.

Z interpretácie modelov vyplýva, že pre rozlíšenie benígnych a malígnych vzoriek sú dôležité najmä features súvisiace s veľkosťou nádoru, konkávnosťou, počtom konkávných bodov, textúrou a hladkosťou. Tieto výsledky sú intuitívne, pretože malígne vzorky bývajú často nepravidelnejšie a majú odlišné morfológické vlastnosti.

Ako možné zlepšenie by bolo vhodné vyskúšať opakované rozdelenie train/test alebo nested cross-validation, aby sa lepšie overila robustnosť modelov. Ďalším rozšírením by mohlo byť detailnejšie ladenie prahu rozhodovania pri SVM a logistickej regresii s cieľom minimalizovať falošne negatívne prípady.